

Final Report for ML Term Project

- Netflix Rating System(11조)



Subject : 기계학습

Instructor : 강재우

Student ID / Name : 2017120016 / 송태훈

2020390472 / 이유림

2021170220 / 전강석

Date : 2023/10/26

1. Task Definition


넷플릭스나 디즈니 플러스와 같은 많은 OTT 플랫폼은 각 작품에 대한 간략한 'Overview'를 제공한다. Overview는 작품의 요약된 줄거리를 요약할 뿐만 아니라 흥미로운 부분을 강조하여 시청자의 주목을 끈다. 이를 통해 시청자들은 작품의 분위기와 내용을 파악하고, 이 정보를 기반으로 콘텐츠를 선택할 수 있다.

OTT 시장은 꾸준한 성장을 지속하고 있으며, 2023년 1분기 기준으로 넷플릭스는 전 세계 유료 회원 수가 2억 3250만 명을 넘어 81억 달러 이상의 매출을 기록했고, 디즈니플러스도 1억 5780만 명 가량의 유료 가입자와 33억 달러 가량의 영업 수익을 기록했다. 특히, 코로나 팬데믹으로 인해 OTT 플랫폼은 급속한 성장을 이루었으며, 이러한 흐름은 계속되고 있다. 이로 인해 다양한 플랫폼에서 제공되는 콘텐츠 양은 급증하고 있지만, 사용자들은 이러한 다양한 콘텐츠 중에서 자신에게 맞는 것을 찾기 어렵다는 일명 '풍요 속의 빈곤' 문제가 발생하고 있다. 또한, 새로운 콘텐츠는 평점이 부여되기까지 시간이 걸리므로 사용자들은 콘텐츠의 품질을 사전에 파악하기 어려워 실패 가능성을 감수해야 하는 불편함을 겪는다.

이에 우리는 작품의 overview와 해당 작품의 평점('Rating')간의 연관성을 학습하여 overview가 주어졌을 때 영화의 평점을 예측하는 모델을 생성하고자 한다. 이를 통해 새로운 작품이 출시될 때 해당 작품의 평점을 빠르게 예측하고, 이를 기반으로 유사한 취향을 가진 시청자들에게 추천할 수 있을 것이다. 또한, 시청자들은 예상 평점을 받게 되므로 자신의 취향에 맞는 영화를 믿고 선택할 수 있어 콘텐츠 소비 결정에 도움이 될 것이다. 더 나아가, 줄거리가 간결하게 표현된 Overview로 평점을 예측할 수 있는 모델을 개발한다면, 제작자들은 영화의 성공을 사전에 예측하는 데 이를 활용할 수 있을 것이다.

2. Method

2.1. Data information



[Figure 1]

모델 훈련에는 두 가지 원본 데이터 세트를 활용하였다. 첫 번째로 Kaggle에서 얻은 "Netflix popular movies dataset"은 약 9,957개의 데이터 샘플로 구성되어 있으며, 각각의 샘플은 영화 제목, 출연 배우, 런타임, 평점, 발행 연도, 장르, 그리고 Overview와 같은 여러 feature를 포함하고 있다. 두 번째로 "Top 10000 Popular Movies Dataset"은 10,000개의 데이터 샘플로 구성되어 있으며, 각 샘플은 id, 언어, 제목, 인기도, 발행일, 평점, 평점 수, 장르, Overview, 수익, 런타임과 같은 다양한 feature를 가지고 있다. 우리의 주요 목표는 Overview를 활용하여 영화의 평점을 예측하는 것이다. 따라서, 두 원본 데이터에서 Overview와 Rating만을 추출하여 이를 포함한 새로운 데이터셋을 구성하여 학습에

사용하였다. 이 때, Overview는 문자열(string) 형식의 feature이며, 각 Overview의 평균 길이는 250자이다. 새롭게 구성된 데이터셋은 총 17,065개의 데이터 샘플로 이루어져 있다. 또한, 추후에 언급될 Prompt Engineering을 이용한 RoBERTa¹ 방식을 활용한 학습도 진행하였는데, 이를 위해 genre까지 포함한 데이터셋을 genre를 포함한 데이터셋도 구축했다.

데이터셋을 구성한 후, 이를 훈련 집합(training set)과 시험 집합(test set)으로 8:2 비율로 나누었다. Figure 1은 훈련 집합에서 각 평점 구간별 데이터 수를 보여주고 있으며, 이 그래프를 통해 주로 5-8 사이의 평점 값이 분포하는 것을 확인할 수 있다. 또한, Dataloader를 활용하여 훈련 집합과 시험 집합에 대한 배치 크기를 각각 16로 설정하였다.

2.2. Method Description

2.2.1 Regression

첫째로, Regression 방법론을 활용하여 rating을 직접적으로 예측하는 방식을 진행하였다. 사용한 모델은 transformer 기반의 NLP 모델인 RoBERTa이다. RoBERTa는 BERT²(Bidirectional Encoder Representations from Transformers) 모델을 기반으로 개선된 NLP 모델로, 텍스트 데이터 전처리 과정에서 특정 단어를 random하게 마스킹해 모델에 입력한 후 마스킹된 단어를 예측하도록 학습하는 BERT와 달리, RoBERTa는 데이터를 매번 모델에 입력할 때마다 텍스트에서 다른 부분을 마스킹하여 학습하는 dynamic masking 방식을 사용한다. RoBERTa의 개선된 학습 방식은 같은 양의 데이터라도 더 효과적으로 활용하여 보다 많은 언어 특성과 문맥을 파악 가능하다. 대규모 웹 스케일 텍스트 데이터에 대해서 학습된 RoBERTa는 다양한 downstream task에서 좋은 성능을 보였기에 이번 프로젝트의 모델로 활용했다.

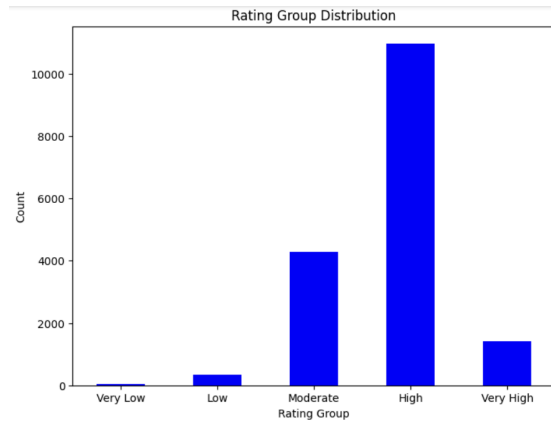
또한 Baseline 비교를 위해 GP Regression³을 사용했다. GP Regression은 Gaussian Process Regression의 약자로 non-parametric하며 Bayesian 접근 방식의 알고리즘이다. GP Regression은 함수의 분포를 확률적으로 모델링하는데, 데이터에 함수를 fitting하는 대신 함수의 모든 가능한 형태에 대한 확률 분포를 나타낸다. 각 함수는 무한한 차원 공간에서 정의되며, observed된 data를 기반으로 함수의 분포를 업데이트하고 새로운 input에 대한 출력을 예측한다. 예측 결과에 대한 신뢰 구간 정보를 제공하여 모델의 예측 불확실성 또한 추정할 수 있다는 장점이 있다. GP Regression은 함수에 대한 확률적 모델로 작용하여 데이터가 적어도 데이터 간의 관계를 확률 분포로 모델링하여 유용한 정보를 더 잘 활용할 수 있다. Metric으로 test set에 대한 average MSE loss를 활용하여 성능 비교를 진행하였다.

2.2.2 Classification

¹ Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., and Stoyanov, V. Roberta: A robustly optimized bert pretraining approach. arXiv preprint arXiv:1907.11692, 2019.

² Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805, 2018.

³ Williams, C. K. I. and Rasmussen, C. E. Gaussian processes for machine learning. 2006.



[Figure 2]

둘째로, regression을 활용한 rating 예측이 적절한 예측을 하지 못하는 것을 확인하여, rating 구간을 5개의 bin으로 나누어 multi-class classification 문제로 접근을 해보았다. Classification 문제로 task를 재정의했을 때 regression보다 본 프로젝트의 목적과 더 align된다. 좋은 영화와 나쁜 영화를 구분하고자 하는 프로젝트의 목표를 달성하기 위해, {'Very Bad': 0, 'Bad': 1, 'Moderate': 2, 'Good': 3, 'Very Good': 4}의 class를 예측하도록 하는 모델이, rating 자체를 소수점까지 예측하려는 regression의 접근보다 더 효과적이고 직관적이다. 구간을 5개로 나눈 이유는, 많은 리뷰 사이트에서 채택하고 있는 5-star rating 시스템과 가장 직관적으로 일치하기 때문이다. 그러나, 현재 활용하고 있는 데이터셋은 rating에 대해서 굉장히 unbalanced한 데이터셋이다. 특히, rating 6-8 구간을 나타내는 class가 학습 데이터의 약 64%를 차지하고 있기 때문에, metric으로 accuracy를 활용하는 것은 적절하지 않아 보인다. 모델이 전혀 학습을 하지 않고 모든 데이터에 대해서 rating 6-8 구간 class를 예측할 경우에도 64%의 accuracy를 보여주기 때문이다. 그렇기 때문에, metric으로 우리는 weighted f1-score를 활용하여 모델의 성능을 비교할 것이다. 모델의 경우, regression과 마찬가지로, RoBERTa 모델을 활용할 예정이다.

2.3. Training Method

이 프로젝트에서 모델을 학습시킨 방식은 크게 3가지로 나눌 수 있다 : RoBERTa Model (Without Prompt Engineering), RoBERTa Model (With Prompt Engineering), GP Regression. Regression과 Classification 모두에 대해서 pretrain된 RoBERTa-base 모델에 간단한 MLP head만 추가하여 finetuning 학습을 진행하였다, 중간 연구 이전까지는 roBERTa를 freeze하여 진행하였으나, 성능 향상을 위하여 이후에는 전체 model에 대한 fine tuning을 진행하였다. 구체적으로, dense layer-ReLU를 세 개 쌓은 head에 활용하였고, RoBERTa의 마지막 layer의 embedding을 mean pooling하여 head의 input으로 활용하였다. Regression의 경우 loss function으로 MSE loss를, Classification의 경우에는 Cross entropy loss를 활용하였다. 현재 데이터셋이 불균형함이 심하므로, Cross entropy loss의 weight 인자에 클래스별 학습 데이터의 빈도의 역수를 가중치로 활용하였다. Optimizer으로 adam을 활용하였고, learning rate는 1e-05을 활용하였다. RoBERTa Model (Without Prompt Engineering)의 경우, input으로 overview text를 활용하여 tokenize를 시킨 후 rating을 예측할 수 있도록 하였다. 이후 prompt engineering을 활용하여, overview text 이외에 genre도 같이 input으로 넣는 방식을 채택하였다. 이때 활용한 prompt는 'This movie's genre is {...}, This movie's overview is {...}.'이다. 이러한 hard prompt는 Vision-language model인 CLIP⁴에서 text encoder에


⁴ Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., and Sutskever, I. Learning transferable visual models from natural language supervision, 2021.

'A photo of a {}'라는 hard prompt를 활용하여 성능 향상을 확인 한 것에서 아이디어를 착안하였다. 마지막으로, regression baseline으로 활용하기 위해 RoBERTa 모델에서 뽑아낸 overview text embedding을 input으로 활용하는 GP regression을 시도했다. GP regression의 경우, mean function으로는 constant mean, 그리고 covariance function으로는 RBF(Radial Basis function)을 활용하였다. Gp regression의 경우에도, Adam optimizer를 활용하였고, learning rate는 $1e-2$ 을 활용하였다. 세 모델 모두 colab 환경에서 T4 gpu 1개를 활용하여 학습을 진행하였다.

3. Results & Interpretation

3.1. Regression


3.1.1 GP Regression



[Figure 3]

Figure 3는 RoBERTa를 활용하여 추출한 임베딩을 GP Regression 모델에 적용한 결과를 보여준다. 파란색 선(예측 값)이 검은 별(실제 값)들의 분포를 잘 예측하지 못하는 것을 확인할 수 있다. 물론, Confidence 영역 내에서 검은 별들이 밀집되어 있기 때문에 어느 정도의 적합성을 나타내기는 하지만, 이 역시 데이터셋의 평점 분포가 주로 5-8 사이에 집중되어 있음을 반영하고 있을 가능성이 있다. 이를 통해 두 가지 중요한 사실을 예측할 수 있다. 첫째로, 데이터의 평점 분포가 특정한 값 주변에 집중되어 있기 때문에, 입력 데이터가 주로 평점 예측에 기여하는 것보다는 데이터 분포 자체가 중요한 영향을 미친다는 것이다. 즉, 모델은 데이터 자체의 특성을 파악하고 해당 분포를 따르는 경향이 있다. 둘째로, 단일한 overview 입력만으로는 평점을 정확하게 예측하는 것이 어렵다는 것이다. 이것은 영화 평점을 결정하는 데에는 다양한 요인들이 작용하며, 이러한 복잡성은 단순한 overview 정보로 충분히 설명되기 어렵다는 것을 시사한다. 따라서, 이러한 결과를 토대로 모델의 한계와 개선점을 고려하는 것이 미래의 예측 모델을 개발하는 데 고려할 점이다.


3.1.2 RoBERTa without Prompt



[Figure 4]

Figure 4는 RoBERTa 모델에 MLP Head를 추가한 뒤, 'description' 데이터를 input으로 넣어 rating을 예측하도록 regression을 진행한 것이다. figure 통해 우리는 프롬프트를 사용하지 않은 RoBERTa 모델은 예측 성능이 좋지 않다는 것을 확인할 수 있다. 빨간 점은 실제 값, 파란색 선은 예측 값을 나타내는데 예측 값들이 실제 값과 거의 일치하지 않고 주로 6.3 정도에서 머무르는 것을 확인할 수 있다. 이러한 현상을 분석해보면, Figure 3에서 나타난 것처럼 훈련 데이터셋의 평점이 대부분 5에서 8 사이에 분포하고 있어서, 간단하게 5에서 8 사이의 중간값을 예측하는 것이 전체 손실을 최소화하는 데 적합했을 것으로 생각된다. 이는 description feature가 rating 예측에 충분한 영향을 미치지 못했다는 것을 시사할 수도 있다.

3.1.3 RoBERTa with Prompt



[Figure 5]

Figure 5는 RoBERTa 모델에 MLP Head를 추가한 뒤, 프롬프팅을 통해 생성한 데이터로 rating을 regression의 방법론으로 예측한 결과이다. 'description'만을 통해 rating을 예측한 모델의 성과가 만족스럽지 않아 우리는 "overview" 외에도 genre 정보를 추가 input으로 활용하기로 결정했다. 이때, 프롬프트는 'This movie's genre is {...}, This movie's overview is {...}.'로 설정되었다. 우선, 공정한 비교를 위해 RoBERTa (without Prompt) 모델을 동일하게 20epoch 동안 학습시킨 후 validation set에서의 MSE를 확인했다. 그 결과 파란 선은 주로 6점과 7점 사이에 머무는 것으로 나타난다. 프롬프팅을 진행하지 않은 regression보다는 개선되어 보이지만, 정확도는 여전히 우리의 기대 이하의 수준이었다. 이러한 예측 결과가 나타나는 이유로는 데이터가 굉장히 불균형한 상황에서, 다수의 데이터

평점이 5에서 8 사이에 집중되어 있기 때문으로 추측된다. 세 그래프 모두 실제 데이터가 여러 방향으로 분산되어 있음을 감안할 때, rating을 예측하도록 정확하게 모델링하는 것은 어려울 수도 있어 보인다.

3.1.4 Regression Analysis

	RoBERTa (w/o Prompt) (20 epochs)	RoBERTa (w/ Prompt) (20 epochs)	GP Regression
Average Loss	1.36	1.30	1.58

[Table 1]

위의 Table은 각 학습 방식별로 validation set에 대한 MSE Loss를 소수점 두 번째 자리까지 계산한 것이다. MSE Loss를 비교해볼 때, RoBERTa (with prompt) (20 epoch) 방식이 가장 낮은 손실을 가지고 있음을 확인할 수 있다. 다만, 각 방식의 정확한 분포를 확인하기 위해서는 Average loss만으로 충분하지 않기 때문에, 모델별로 예측값과 실제값을 시각화한 그래프를 통해 확인하고자 했다. Figure 3, 4, 5에서 각 모델별로 validation set에 대한 prediction과 real value를 시각적으로 확인할 수 있다. 시각화 결과를 보면 MSE loss 가장 큰 GP Regression이 직관적으로는 오히려 좋은 예측을 할 수 있다고 판단된다. 또한, "+ with prompt" 방식을 사용할수록 MSE 손실이 감소하지만, 예측 값에 대한 variance가 줄어들고 accuracy도 떨어지는 것을 시각적으로 확인할 수 있었다.

3.2 Classification

3.2.1 RoBERTa without Prompt

label	precision	recall	f1 score
0	0.00	0.00	0.00
1	0.06	0.05	0.05
2	0.34	0.71	0.46
3	0.73	0.30	0.42
4	0.19	0.46	0.27

[Table 2]

Regression 방식을 통한 prediction이 한계가 있다고 느낀 우리는 rating을 5개의 구간으로 나누어 multi-class-classification 방식으로 접근해보기로 하였다. Table 2는 Prompt가 없는, 즉 description 데이터 만으로 rating을 classification한 결과이다. 이때의 RoBERTa 모델은 후에 진행한 regression과 같이 roberta 전체를 finetune시켜 학습에 활용하도록 설정하였다. 각 label은 영화의 평점이 0점 이상 2점 미만, 2점 이상 4점 미만, 4점 이상 6점 미만, 6점 이상 8점 미만, 8점 이상 10점 이하로 0(very low), 1(low), 2(moderate), 3(high), 4(very high)로 구분되어 분류되었다. precision은 3번 label에서 가장 높게 나타났으며, recall은 2번 label이 가장 높았고, f1 score 또한 2번 label이

가장 높았다. 평가 데이터셋의 클래스가 불균형성을 고려하였을 때, precision과 recall을 적절히 고려한 f1 score가 가장 높은 2번 label(moderate)에 대한 분류 성능이 가장 좋았으며, 3번, 4번 label이 뒤를 이었다.

3.2.2 RoBERTa with Prompt

label	precision	recall	f1 score
0	0.00	0.00	0.00
1	0.12	0.03	0.05
2	0.39	0.50	0.44
3	0.71	0.46	0.56
4	0.19	0.59	0.29

[Table 3]

Table 3는 Prompt가 있는, 즉 overview 데이터에 prompt를 genre를 추가한 새로운 input으로 rating을 classification한 결과이다. 각 label에 대한 분류 기준과 label이 상징하는 것은 앞의 classification without prompt와 같다. precision은 3번 label이 가장 높았으며, recall은 4번 label이 가장 높았다. f1 score의 경우 3번 label(high)에 대한 분류 성능이 가장 좋았으며, 2번과 4번 label이 그 뒤를 따랐다. classification without prompt와 비교하였을 때, 전반적으로 prompt를 추가한 모델이 성능이 향상되었음을 볼 수 있었으며, 특히 좋은 영화를 사용자에게 먼저 추천하는 데 유용한 3번(high)와 4번(very high)에 대한 예측이 증가하였음을 확인할 수 있었다.

3.2.3 Summary Statistics

	RoBERTa (w/o Prompt) (20 epochs)	RoBERTa (w/ Prompt) (20 epochs)
Accuracy	0.41	0.47
f1-score(macro)	0.22	0.27
f1-score(weighted)	0.41	0.49
Average Cross Entropy	1.37	1.35

[Table 4]

Classification에 대해서는 RoBERTa Model (Without Prompt Engineering), RoBERTa Model (With Prompt Engineering) 두 가지 모델을 활용하였다. Table 4에서 각 모델을 20 epoch 학습시켰을 때의 summary statistics를 확인할 수 있다. RoBERTa Model (With Prompt Engineering)의 성능이 RoBERTa Model(Without Prompt Engineering)의 성능보다 좋은 것을 확인할 수 있다. RoBERTa

Model(With Prompt Engineering)이 RoBERTa Model(Without Prompt Engineering)에 prompt와 genre 정보만 추가로 활용했음에도 weighted f1-score에 대해서 0.08 point의 향상을 보여주었다. 이는 출연 배우, 감독과 같은 추가적인 영화 특성을 input으로 더 추가하거나 고도화된 prompt engineering 방법을 활용하면 더 큰 성능 향상을 이룰 수 있다는 가능성을 시사한다.

3.3 Conclusion

우리는 netflix rating 데이터셋을 regression과 classification 두 가지 task로 나누었으며, 각각 without prompt(description only)와 with prompt(with genre) 두 가지 방식으로 적용시켜 모델 간의 성능 차이를 비교했다. 표 1과 표 4는 각각 netflix rating 예측에 대한 regression과 classification 결과를 보여준다. 종합적으로, 영화와 드라마의 rating을 예측하는데 있어 with prompt 모델이 without prompt 모델보다 우수한 성과를 냈다. 구체적으로, regression task에서는 regression with prompting 모델이 1.30로 average loss가 가장 낮았으며, classification task에서는 classification with prompting 모델의 weighted f1 score가 0.49로 가장 높았다.

4. Limitations & Future Research

4.1 Limitations

본 프로젝트에서는 자연어 feature인 영화의 줄거리를 나타내는 overview와 genre를 활용하여 영화의 rating을 예측할 수 있는 모델에 집중하였다. 하지만, 이러한 NLP만을 활용한 접근은 영화의 rating을 예측하는데 내재적인 한계가 있다. 먼저, 사람들이 영화의 평점을 매기는데에는 영상미, 촬영기법, 배우들의 연기 등의 자연어로 표현하기 힘든 여러가지 요인들이 작용한다. 나아가, 본 프로젝트의 모델을 학습함에 있어 영화의 평점에 영향을 줄 수 있는 출연 배우, 감독 등 자연어로 표현할 수 있는 추가적인 feature가 kaggle의 활용 데이터에 존재하지 않아 해당 feature를 가진 데이터 확보에 어려움이 있었다. 자연어로 표현 가능한 영화의 다양한 feature 중 극소수만 활용했다는 것이 본 모델의 예측 과정에서의 한계이다.

또한 Task Definition에서 언급한 것처럼 이 모델의 주 목적 중 하나는 시청자의 취향에 맞는 영화를 제공하는 것이다. 하지만 본 프로젝트에서 학습시킨 모델은 영화의 overview와 genre를 통해 영화의 rating을 예측하는 모델이며, rating을 예측하는 것만으로는 개인의 취향에 맞는 영화를 추천하기는 어렵다. 시청자에 관한 정보를 반영하지 않고 단순히 rating이 높은 영화를 추천한다면 해당 영화가 시청자 개인의 취향에 맞지 않을 수 있기 때문이다.

4.2 Future Research

위의 Limitation들을 해결하기 위해, 우선은 최대한 많은 자연어 feature들을 반영할 수 있는 데이터셋을 수집해야 할 것이다. 이때 사용할 수 있는 데이터셋은 TMDB API로, TMDB는 영화와 텔레비전 프로그램에 관한 정보를 제공하는 온라인 데이터베이스 및 웹사이트로써 영화 및 TV 프로그램의 리뷰, 평점, 출연진 정보, 스태프 정보, 키워드, 제작비, 등장인물 정보, 크레딧 및 제작사 정보 등을 수집하고 관리한다. 즉 TMDB API를 통해 데이터셋을 수집한다면 영화에 관한 최대한 많은 데이터를 수집할 수 있다. 추가된 데이터들을 포함한 prompt로 학습을 진행하게 된다면 성능 향상을 기대할 수 있다.

또한 사용자가 선호하는 genre나 영화 데이터를 입력받으면, 해당 genre나 비슷한 내용의 overview를 가진 데이터에 대한 weight 계산량을 늘려 rating 예측에 대한 영향을 높이는 방식으로 모델을 설계할

수 있다. 위 방식을 통해서 사용하는 사용자의 데이터와 유사한 데이터들이 rating에 영향을 크게 미칠 것이므로, 개인의 취향에 맞는 rating을 예측하여 사용자에게 제공할 수 있다.

영상 내용 자체를 AI가 이해하고 이를 학습에 반영시키는 방식 또한 사용될 수 있다. 최근 Deep Summarization Network⁵를 통해 영상 데이터를 이용하여 해당 영상의 요약물 작성하는 딥러닝 기법이 소개되었고, 이후 다양한 영상 요약 AI(Traw, glarity)가 등장하였다. 따라서 해당 프로그램을 이용해 영화 영상 자체에 대한 summary prompt를 스스로 생성해 해당 정보도 학습에 반영시키는 방식을 사용하거나, 혹은 DSN에서 summary prompt를 생성하는 방식을 응용해 영상 자체의 데이터를 학습시켜 다른 원하는 정보를 추출해내는 방향으로도 연구가 이루어질 수 있다.

Reference

- [1] Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., Levy, O., Lewis, M., Zettlemoyer, L., and Stoyanov, V. Roberta: A robustly optimized bert pretraining approach. arXiv preprint arXiv:1907.11692, 2019.
- [2] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805, 2018.
- [3] Williams, C. K. I. and Rasmussen, C. E. Gaussian processes for machine learning. 2006.
- [4] Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., and Sutskever, I. Learning transferable visual models from natural language supervision, 2021.
- [5] Kaiyang Zhou, Yu Qiao, T. X. Deep reinforcement learning for unsupervised video summarization with diversity-representativeness reward. 2018

⁵ Kaiyang Zhou, Yu Qiao, T. X. Deep reinforcement learning for unsupervised video summarization with diversity-representativeness reward. 2018